




فصل پنجم: مثال(رگرسیون چند جمله ای)









□ بیشبرازش. اگر تعداد ویژگیها بسیار زیاد باشد، فرضیه یاد گرفته شده ممکن است دادههای آموزشی را خیلی خورد. خوب یاد بگیرد، اما این امکان نیز وجود دارد که این فرضیه در پیشبینی دادههای جدید شکست بخورد. [عدم قابلیت تعمیم]


فصل پنجم: مثال(رگرسیون لجستیکی)




$$h_{\theta}(x) = g(\theta_0 + \theta_1 x_1 + \theta_2 x_2)$$

($g = \text{sigmoid function}$)





$$g(\theta_0 + \theta_1 x_1 + \theta_2 x_2)$$




$$g(\theta_0 + \theta_1 x_1 + \theta_2 x_1^2 + \theta_3 x_1^2 x_2 + \theta_4 x_1^2 x_2^2 + \theta_5 x_1^2 x_2^3 + \theta_6 x_1^3 x_2$$

مرل صميح

بیش برازش (واریانس بالا)

فصل پنجم: بیش برازش




فصل پنجم: برخورد با بیش برازش



- تعداد اتاقها : χ_2
- تعداد طبقات : 𝗓 عداد
 - تدمت: ${\mathcal X}_4$
- اندازه آشپزخانه: χ_5
- اتعداد سرویسها : χ_6
 - ...
- میانگین درآمد همسایهها: χ_{100}







فصل پنجم: برخورد با بیش برازش

- □ راهحلهای ممکن.
- 🗖 کاهش تعداد ویژگیها.
- به صورت دستی ویژگیهای مهمتر را انتخاب و بقیه را حذف کن.
 - الگوريتمهاي انتخاب مدل [در ادامه]
 - 🗖 تنظیم. (رگولاریزاسیون)
 - همه ویژگیها را نگهدار، اما مقدار پارامترهای θ_i را کاهش بده.
- زمانی که ویژگیهای بسیاری داریم که هر کدام سهم اندکی در پیشبینی مقدار خروجی دارند، این روش به خوبی عمل میکند.

تابع هزینه

فصل پنجم: مفهوم تنظيم






$$\theta_0 + \theta_1 x + \theta_2 x^2 + \theta_3 x^3 + \theta_4 x^4$$

□ تابع هزینه.

می توان با جریمه کردن تابع هزینه، مقادیر پارامترهای θ_* و θ_* را بسیار کوچک نمود:

$$\min_{\theta} \frac{1}{2} \sum_{i=1}^{m} (h_{\theta}(x^{(i)}) - y^{(i)})^{2} + 1000\theta_{3}^{2} + 1000\theta_{4}^{2} \approx 0 \approx 0$$

فصل پنجم: مفهوم تنظيم



	M = 0	M = 1	M = 6	M = 9
w_0^{\star}	0.19	0.82	0.31	0.35
w_1^{\star}		-1.27	7.99	232.37
w_2^{\star}			-25.43	-5321.83
$w_3^{\tilde{\star}}$			17.37	48568.31
w_4^{\star}				-231639.30
w_5^{\star}				640042.26
w_6^{\star}				-1061800.52
w_7^{\star}				1042400.18
w_8^{\star}				-557682.99
w_9^{\star}				125201.43
9	l.			


فصل پنجم: تنظیم

- □ تنظیم. استفاده از مقادیر کوچک برای پارامترهای «تتا» □ ایجاد فرضیههای «سادهتر»
 - «اصل تراش او کام»: تراشیدن اجزای غیر ضروری از مدل
 - □ کاهش خطر بیشبرازش
 - □ مثال.
 - $oldsymbol{\mathcal{X}}_{100}$ ویژگیها: $oldsymbol{\mathcal{X}}_1$ ، $oldsymbol{\mathcal{X}}_2$ ، $oldsymbol{\mathcal{X}}_1$
 - θ_{100} پارامترها: θ_0 ، θ_1 ، θ_0 ... و θ_{100}

 $J(\theta) = \frac{1}{2} \left[\sum_{i=1}^{m} (h_{\theta}(x^{(i)}) - y^{(i)})^{2} + \lambda \sum_{j=1}^{n} \theta_{j}^{2} \right]$

فصل پنجم: تنظیم

□ تنظيم.



$$J(\theta) = \frac{1}{2} \left[\sum_{i=1}^{m} \left(h_{\theta}(x^{(i)}) - y^{(i)} \right)^2 + \lambda \sum_{j=1}^{n} \theta_j^2 \right]$$

$$\min_{\theta} J(\theta)$$

فصل پنجم: پرسش كلاسي

□ در رگرسیون خطی تنظیم شده، مقادیر پارامترها به گونهای انتخاب میشوند که مقدار تابع هزینه کمینه گردد.

$$J(\theta) = \frac{1}{2} \left[\sum_{i=1}^{m} (h_{\theta}(x^{(i)}) - y^{(i)})^{2} + \lambda \sum_{j=1}^{n} \theta_{j}^{2} \right]$$

س. اگر ضریب تنظیم λ را با یک مقدار بسیار بزرگ مقداردهی کنیم (مثلاً ۱۰۱۰)، در این صورت چه خواهد شد؟

- الگوریتم به خوبی کار می کند و مقدار بزرگ λ آسیبی به آن وارد نمی کند.
 - □ الگوریتم در برخورد با بیشبرازش شکست میخورد.
 - □ الگوریتم با کمبرازش پایان میپذیرد.
 - 🗖 الگوریتم گرادیان کاهشی همگرا نمیشود.

فصل پنجم: پرسش کلاسی

□ در رگرسیون خطی تنظیم شده، مقادیر پارامترها به گونهای انتخاب میشوند که مقدار تابع هزینه کمینه گردد.

$$J(\theta) = \frac{1}{2} \left[\sum_{i=1}^{m} (h_{\theta}(x^{(i)}) - y^{(i)})^{2} + \lambda \sum_{j=1}^{n} \theta_{j}^{2} \right]$$

س. اگر ضریب تنظیم λ را با یک مقدار بسیار بزرگ مقداردهی کنیم (مثلاً ۱۰۱۰)، در این صورت چه خواهد شد؟

رگرسیون غطی تنظیم شده

فصل پنجم: رگرسیون خطی تنظیم شده

□ تابع هزينه.

$$J(\theta) = \frac{1}{2} \left[\sum_{i=1}^{m} (h_{\theta}(x^{(i)}) - y^{(i)})^{2} + \lambda \sum_{j=1}^{n} \theta_{j}^{2} \right]$$

$$\min_{\theta} J(\theta)$$

فصل پنجم: گرادیان کاهشی (بدون تنظیم)

□ بدون استفاده از تنظیم.

repeat until convergence {

$$\theta_j = \theta_j - \alpha \sum_{i=1}^m (h_\theta(x^{(i)}) - y^{(i)}) \cdot x_j^{(i)}$$
 $(j = 0, 1, 2, ..., n)$

فصل ینجم: گرادیان کاهشی (با تنظیم)

□ با استفاده از تنظیم.

repeat until convergence {
$$\theta_0 = \theta_0 - \alpha \sum_{i=1}^m (h_\theta(x^{(i)}) - y^{(i)}) \cdot x_0^{(i)}$$

$$\theta_j = \theta_j - \alpha \left[\sum_{i=1}^m (h_\theta(x^{(i)}) - y^{(i)}) \cdot x_j^{(i)} + \lambda \theta_j \right] \qquad (j = 1, 2, ..., n)$$

$$\theta_j = \theta_j (1 - \alpha \lambda) - \alpha \sum_{i=1}^m (h_\theta(x^{(i)}) - y^{(i)}) \cdot x_j^{(i)}$$

فصل ينجم: معادله نرمال

$$X = \begin{bmatrix} (x^{(1)})^T \\ \vdots \\ (x^{(m)})^T \end{bmatrix}$$

$$y = \begin{bmatrix} y^{(1)} \\ \vdots \\ y^{(m)} \end{bmatrix}$$

$$X \theta = y$$

$$heta_0$$
 عرم استفاره از تنظیم برای پارامتر

$$\theta = \begin{pmatrix} X^T X + \lambda \begin{bmatrix} 0 & 0 & 0 & \cdots & 0 \\ 0 & 1 & 0 & \cdots & 0 \\ 0 & 0 & 1 & \cdots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \cdots & 1 \end{bmatrix} \end{pmatrix}^{-1} X^T y$$

فصل ينجم: معكوس نايذيري

m < n فرض کنید

$$\theta = (X^T X)^{-1} X^T y$$

 $\lambda > 0$ اگر

$$\theta = \begin{pmatrix} X^T X + \lambda \begin{bmatrix} 0 & 0 & 0 & \cdots & 0 \\ 0 & 1 & 0 & \cdots & 0 \\ 0 & 0 & 1 & \cdots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \cdots & 1 \end{bmatrix} \end{pmatrix}^{-1} X^T y$$

معكوس پذير

۲۰ رگرسیون لمستیکی تنظیم شده

فصل پنجم: رگرسیون لجستیکی

$$h_{\theta}(x) = g(\theta_0 + \theta_1 x_1 + \theta_2 x_1^2 + \theta_3 x_1^2 x_2 + \theta_4 x_1^2 x_2^2 + \theta_5 x_1^2 x_2^3 + \cdots)$$

□ تابع هزينه.

$$J(\theta) = -\sum_{i=1}^{m} y^{(i)} \log h_{\theta}(x^{(i)}) + (1 - y^{(i)}) \log (1 - h_{\theta}(x^{(i)}))$$

فصل پنجم: رگرسیون لجستیکی

$$h_{\theta}(x) = g(\theta_0 + \theta_1 x_1 + \theta_2 x_1^2 + \theta_3 x_1^2 x_2 + \theta_4 x_1^2 x_2^2 + \theta_5 x_1^2 x_2^3 + \cdots)$$

□ فرضيه.

□ تابع هزينه.

$$J(\theta) = -\sum_{i=1}^{m} y^{(i)} \log h_{\theta}(x^{(i)}) + (1 - y^{(i)}) \log \left(1 - h_{\theta}(x^{(i)})\right) + \frac{\lambda}{2} \sum_{i=1}^{m} \theta_{j}^{2}$$

فصل ینجم: گرادیان کاهشی

□ با استفاده از تنظیم.

repeat until convergence {
$$\theta_0 = \theta_0 - \alpha \sum_{i=1}^m (h_\theta(x^{(i)}) - y^{(i)}) \cdot x_0^{(i)}$$

$$\theta_j = \theta_j - \alpha \left[\sum_{i=1}^m (h_\theta(x^{(i)}) - y^{(i)}) \cdot x_j^{(i)} + \lambda \theta_j \right] \qquad (j = 1, 2, ..., n)$$
 }

$$h_{\theta}(x^{(i)}) = \frac{1}{1 + e^{-\theta^T x^{(i)}}}$$

فصل پنجم: بهینه سازی پیشرفته

```
function [jVal, gradient] = costFunction(theta)
          jVal = [code to compute I(\theta)];
                            J(\theta) = \left[ -\sum_{i=1}^{m} y^{(i)} \log h_{\theta}(x^{(i)}) + (1 - y^{(i)}) \log (1 - h_{\theta}(x^{(i)})) \right] + \frac{\lambda}{2} \sum_{i=1}^{n} \theta_{i}^{2}
          gradient(1) = [code to compute \frac{\partial}{\partial \theta_0} J(\theta)];
                           \sum_{i=0}^{m} \left(h_{\theta}\left(x^{(i)}\right) - y^{(i)}\right) \cdot x_0^{(i)}
          gradient(2) = [code to compute \frac{\partial}{\partial \theta_1} J(\theta)];
                           \sum (h_{\theta}(x^{(i)}) - y^{(i)}) \cdot x_1^{(i)} + \lambda \theta_1
          gradient(n+1) = [code to compute \frac{\partial}{\partial \theta_n} J(\theta)];
```

با تشکر از توجه شما

